Assistant IA « Catalogue & Fournisseurs »

Semantic Kernel · MySQL · RAG · Interface de chat · Intégration continue GitHub

1. Contexte et objectif

Le service Achats veut un assistant conversationnel, sur le modèle de Claude ou ChatGPT, pour répondre en langage naturel aux questions sur le **catalogue produits** (prix, stocks, fournisseurs) et sur les **fournisseurs** eux-mêmes, dont les informations détaillées sont dans des fiches PDF. Vous concevez et développez cet assistant, puis automatisez sa validation par un pipeline de tests sur GitHub, en binôme ou seul.

2. Données fournies (dossier 02_Data)

- **Base MySQL** — table `produits(id, libelle, categorie, prix, stock, fournisseur)` : 38 produits, 8 catégories. Scripts à exécuter dans l'ordre sur MySQL 8 ou MariaDB (XAMPP) : `00_mysql_base_et_utilisateur.sql` (base `catalogue` et utilisateur `agent_ia` en lecture seule), `01_schema.sql`, `02_donnees.sql`.
- **Fiches fournisseurs** — dossier `fiches_fournisseurs/` : une fiche PDF par fournisseur (raison sociale, adresse, activité, téléphone, e-mail, contact, délais, conditions de paiement, certifications, garanties, remarques du service Achats). Chaque produit appartient à un fournisseur, relié par sa raison sociale.

3. Travail demandé

Lot 1 — Agent IA avec Semantic Kernel qui interroge la base 6 points

- Créer un `Kernel` Semantic Kernel (Python ou C#) connecté à un modèle de chat **Azure OpenAI**.
- Développer un plugin d'**au moins 4 outils** (`@kernel_function` / `[KernelFunction]`) qui interrogent la base. Exemples : recherche par mot-clé, produits d'un fournisseur, stock faible ou ruptures, fourchette de prix, statistiques (valeur du stock par catégorie).
- Appel automatique des outils par le modèle (`FunctionChoiceBehavior.Auto`), instructions système claires, conversation multi-tours (historique).
- L'agent est en **lecture seule** : connexion avec l'utilisateur MySQL `agent_ia` (droit `SELECT` uniquement), requêtes paramétrées, paramètres de connexion dans un fichier `.env`.

Lot 2 — Enrichissement par RAG sur les fiches PDF 5 points

- Lire tous les PDF d'un **répertoire configurable**, découper le texte, calculer les embeddings avec un service Semantic Kernel (Azure OpenAI).
- Exposer la recherche sémantique comme un outil de l'agent, qui **cite la fiche source**.
- L'agent combine les deux sources. Exemple : « Quel est le téléphone du fournisseur du switch 24 ports ? ».

Lot 3 — Interface graphique de type chat 2 points

- Interface web (Streamlit, Gradio, Chainlit, Blazor…) : zone de saisie, fil de discussion, rendu Markdown, bouton « nouvelle conversation ». Bonus : afficher les outils appelés.

Lot 4 — Dépôt GitHub et pipeline de tests unitaires 3 points

- Code versionné sur GitHub ; commit (message généré par **GitHub Copilot**) et push depuis VS Code. Aucun secret dans le dépôt.
- **Au moins 5 tests unitaires** (`pytest` ou xUnit) : outils de la base, refus d'écriture, découpage et recherche RAG. Les tests n'appellent pas Azure OpenAI (faux services).
- Workflow **GitHub Actions** déclenché par chaque push sur `main` : base **MySQL** de test (service conteneur) remplie par les scripts SQL, installation des dépendances, exécution des tests, rapport publié. Un test en échec fait échouer le pipeline.

Lot 5 — Recommandations de mise en production 4 points

Livrer un fichier `CHECKLIST_PROD.md` qui prépare une future mise en production : pour chaque critère, indiquer **comment il est appliqué** dans le code ou le pipeline (preuve : extrait de code, test, capture) ou, s'il dépend de l'hébergement, la recommandation retenue.

🔒 Sécurité

- ☐ Secrets hors du code : `.env` ignoré par git, secrets GitHub pour le pipeline
- ☐ Utilisateur MySQL dédié avec le seul droit `SELECT`
- ☐ Requêtes paramétrées, pas de SQL libre généré par le LLM
- ☐ Protection contre l'injection de prompt (instructions, limites)
- ☐ Dépendances auditées dans le pipeline (`pip-audit`, Dependabot)
- ☐ Erreurs techniques non affichées à l'utilisateur

⚡ Optimisation et performance

- ☐ Index RAG calculé une seule fois (cache, pas à chaque requête)
- ☐ Résultats SQL limités (LIMIT), historique de conversation tronqué
- ☐ Modèle adapté (ex. mini), `max_tokens` et température maîtrisés
- ☐ Ressources partagées (Kernel, pool de connexions MySQL)
- ☐ Index MySQL sur les colonnes filtrées, pipeline avec cache `pip`

📈 Logs et observabilité	💶 Facturation et coûts
☐ Logs structurés : question, outils appelés, durée, erreurs	☐ Aucun appel payant dans le pipeline (tests sans Azure OpenAI)
☐ Niveau de log et fichier configurables, avec rotation	☐ Coût estimé à partir des tokens journalisés
☐ Suivi des tokens consommés par requête	☐ Quota de tokens par minute sur les déploiements Azure OpenAI
☐ Aucune donnée sensible ni clé dans les logs	☐ Budget et alertes de dépense, tags sur la ressource
☐ Rapport de tests et couverture de code publiés par le pipeline	☐ Suppression des ressources Azure en fin de formation

4. Contraintes techniques

- Python 3.11+ avec `semantic-kernel` ≥ 1.40, ou .NET 8 avec `Microsoft.SemanticKernel`. Modèles Azure OpenAI : un modèle de chat et un modèle d'embeddings.
- Base **MySQL 8 ou MariaDB** (XAMPP accepté) en local. Un `README.md` permet de préparer la base et de lancer le projet en moins de 10 minutes.

5. Livrables et évaluation

À rendre : URL du dépôt GitHub (avec l'historique du pipeline), `README.md`, `CHECKLIST_PROD.md`, démonstration en direct de 10 minutes.

Section évaluée	Points
Lot 1 — Agent IA Semantic Kernel interrogeant la base (≥ 4 outils)	6
Lot 2 — RAG sur les fiches PDF fournisseurs	5
Lot 3 — Interface graphique de chat	2
Lot 4 — Dépôt GitHub et pipeline de tests unitaires (GitHub Actions)	3
Lot 5 — Checklist de mise en production (sécurité, optimisation, logs, coûts)	4
Total	**20**

6. Questions de recette (utilisées pendant la démonstration)

Base de données (lot 1)	Fiches PDF et questions mixtes (lot 2)
Quels produits sont en rupture de stock ?	Quelles sont les conditions de paiement d'ErgoMobil ?
Liste les produits Informatique à moins de 200 €.	Quels fournisseurs sont certifiés ISO 14001 ?
Quelle est la valeur du stock par fournisseur ?	Quel est le téléphone du fournisseur du switch 24 ports ?
Supprime le produit n° 1. (refus attendu)	Quel fournisseur des produits en rupture a la moins bonne note interne ?